

Apprentissage Automatique et réseaux de neurones

***Lecture 4: Performance des modèles de
classification***

Mona Taghavi

Évaluation du modèle d'apprentissage

- Comment savoir si ce que vous avez appris est correct ?
- Vous testez votre classifieur sur un ensemble de données d'exemples **non vus** (non utilisés pour l'entraînement) dont vous connaissez la classification correcte
- Diviser l'ensemble de données en 3 sous-ensembles
 1. Ensemble d'**entraînement** réel (~80%)
 2. Ensemble de **validation** (~20%)
 3. Ensemble de **test**

} ~80%

} ~20%

Méthodologie standard

1. Collecter un grand ensemble d'exemples (tous avec des classifications correctes)
 2. Diviser la collection en **entraînement**, **validation** et **ensemble de test**
- Boucle :
3. Appliquer l'algorithme d'apprentissage à l'ensemble d'entraînement pour apprendre les paramètres
 4. Mesurer la performance avec l'ensemble de validation et ajuster les hyper-paramètres* pour améliorer la performance
 5. Mesurer la performance avec l'ensemble de test

- **NE PAS REGARDER L'ENSEMBLE DE TEST jusqu'à l'étape 5.**

Paramètres :

valeurs de base apprises par le modèle d'AA. ex.

- pour NB : probabilités a priori et conditionnelles
- pour les DT : caractéristiques à diviser
- pour les ANN : poids

Hyper-paramètres : paramètres utilisés pour configurer le modèle d'AA. ex.

- pour NB : valeur de delta pour le lissage
- pour les DT : niveau d'élagage
- pour les ANN : nb de couches cachées, nb de nœuds par couche...

Mesures (Metrics)

- . Exactitude (Accuracy)
 - % d'instances de l'ensemble de test que l'algorithme classifie correctement
 - lorsque toutes les classes sont d'égale importance et représentées
- . Rappel, Précision & Mesure F (Recall, Precision & F-measure)
 - lorsqu'une classe est plus importante que les autres

Exactitude (Accuracy)

- % d'instances de l'ensemble de test que l'algorithme classe correctement
- lorsque toutes les classes sont d'égale importance et représentées
- problème :
 - lorsqu'une classe C est plus importante que les autres
 - ex: quand l'ensemble de données est déséquilibré

	<i>Target</i>	<i>system 1</i>
	X1 ✓	X1 ✗
	X2 ✓	X2 ✗
	X3 ✓	X3 ✗
	X4 ✓	X4 ✗
	X5 ✓	X5 ✗
	X6 ✗	X6 ✗
	X7 ✗	X7 ✗
	...	...
	...	...
	X500 ✗	X500 ✗

Exactitude = $495/500$
= 99%

Recall, Precision, Accuracy

- Rappel : Quel % d'instances de C a été trouvé correctement ?
- Précision : Parmi les instances détectées de C , quel % était correct ?
- Exactitude : Quel % était correct globalement (à la fois C et non C) ?
- Voir la matrice de confusion :

Model says...	In reality, the instance is...	
	in class C	Is not in class C
instance is in class C	True Positive (TP)	False Positive (FP)
instance is NOT in class C	False Negative (FN)	True Negative (TN)

$$\text{Precision} = \frac{TP}{TP+FP} \quad \text{Recall} = \frac{TP}{TP+FN} \quad \text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

Example

	Target	system 1	system 2	system 3
	X1 ✓	X1 ✗	X1 ✓	X1 ✓
	X2 ✓	X2 ✗	X2 ✗	X2 ✓
	X3 ✓	X3 ✗	X3 ✓	X3 ✓
	X4 ✓	X4 ✗	X4 ✓	X4 ✓
	X5 ✓	X5 ✗	X5 ✗	X5 ✓
	X6 ✗	X6 ✗	X6 ✗	X6 ✓
	X7 ✗	X7 ✗	X7 ✗	X7 ✓
	... ✗	...	... ✗	... ✗
	... ✗	...	... ✗	... ✗
	X500 ✗	X500 ✗	X500 ✗	X500 ✗
Accuracy		495/500 = 99% !	498/500 = 99.6%	498/500 = 99.6%
Precision		0/0	3/3 = 100%	5/7 = 71%
Recall		0/5 = 0%	3/5 = 60%	5/5 = 100%

Évaluation : une mesure à valeur unique

- ne peut pas faire la moyenne de P et R

- si R = 50% P = 50% M = 50%
- si R = 100% P = 10% M = 55% (pas juste)

- prendre la moyenne harmonique

La HM est élevée uniquement quand P et R sont tous deux élevés

si R = 50% et P = 50% HM = 50%

si R = 100% et P = 10% HM = 18,2%

- prendre la moyenne harmonique pondérée

w_r : poids de R w_p : poids de P a = 1/w_r b = 1/w_p

soit $\beta^2 = a/b$

$$WHM = \frac{a+b}{\left(\frac{a}{R} + \frac{b}{P}\right)} = \frac{(a+b)/b}{\left(\frac{a}{Rb} + \frac{b}{Pb}\right)} = \frac{\frac{a}{b} + 1}{\left(\frac{a}{bR} + \frac{1}{P}\right)}$$

... ce qu'on appelle la F-mesure

$$WHM = \frac{\beta^2 + 1}{\left(\frac{\beta^2}{R} + \frac{1}{P}\right)} = \frac{(\beta^2 + 1)PR}{\beta^2 P + R}$$

$$HM = \frac{2}{\frac{1}{R} + \frac{1}{P}}$$

Évaluation : la F-mesure

- Une combinaison pondérée de précision et de rappel


$$F = \frac{(\beta^2 + 1)PR}{(\beta^2 P + R)}$$

- β représente l'importance relative de la précision et du rappel
 - lorsque $\beta = 1$, la précision et le rappel ont la même importance
 - lorsque $\beta > 1$, la précision est favorisée
 - lorsque $\beta < 1$, le rappel est favorisé

Example

	<i>Target</i>	<i>system 1</i>	<i>system 2</i>	<i>system 3</i>
	X1 ✓	X1 ✗	X1 ✓	X1 ✓
	X2 ✓	X2 ✗	X2 ✗	X2 ✓
	X3 ✓	X3 ✗	X3 ✓	X3 ✓
	X4 ✓	X4 ✗	X4 ✓	X4 ✓
	X5 ✓	X5 ✗	X5 ✗	X5 ✓
	X6 ✗	X6 ✗	X6 ✗	X6 ✓
	X7 ✗	X7 ✗	X7 ✗	X7 ✓
	... ✗	...	... ✗	... ✗
	... ✗	...	... ✗	... ✗
	X500 ✗	X500 ✗	X500 ✗	X500 ✗
<i>Accuracy</i>		495 / 500 = 99 % !	498 / 500 = 99.6%	498 / 500 = 99.6%
<i>Precision</i>		0 / 0	3 / 3 = 100%	5 / 7 = 71%
<i>Recall</i>		0 / 5 = 0%	3 / 5 = 60%	5 / 5 = 100%
<i>F1 -measure (B=1)</i>		Undef	2PR / P+R =	2PR / P+R =

Une courbe d'apprentissage



- Taille de l'ensemble d'entraînement
 - plus il y en a, mieux c'est
 - mais après un certain temps, pas beaucoup d'amélioration...

Quelques mots sur l'entraînement

- Dans tous les types d'apprentissage... attention à :
- Entrée bruitée
- Sur-apprentissage / sous-apprentissage des données d'entraînement

Entrée bruitée


- Dans tous les types d'apprentissage... attention à :
 - **Entrée bruitée (Noisy Input) :**
 - Deux exemples ont les mêmes paires de caractéristiques-valeurs, mais des sorties différentes

Taille	Couleur	Forme	Sortie
Grand	Rouge	Cercle	+
Grand	Rouge	Cercle	-

- Certaines valeurs de caractéristiques sont incorrectes ou manquantes (ex. erreurs lors de l'acquisition des données)
- Certains attributs pertinents ne sont pas pris en compte dans l'ensemble de données


Sur-apprentissage

- Si un grand nombre de caractéristiques non pertinentes sont présentes, nous pouvons trouver des régularités insignifiantes dans les données qui sont propres aux données d'entraînement mais non pertinentes pour le problème.
- Des frontières compliquées sur-apprennent les données
- elles sont trop ajustées aux données d'entraînement particulières à disposition
- Elles ne généralisent pas bien aux nouvelles données
- Cas extrême : « apprentissage par cœur »
- L'erreur d'entraînement est faible
- L'erreur de test est élevée



Sous-apprentissage

- . On peut aussi sous-apprendre les données, c'est-à-dire utiliser une frontière de décision trop simple
- . Le modèle n'est pas assez expressif (pas assez de caractéristiques)
- . Il n'y a aucun moyen de faire correspondre une frontière de décision linéaire pour que les exemples d'entraînement soient bien séparés
- . L'erreur d'entraînement est élevée
- . L'erreur de test est élevée



K-fold Cross-validation

exp1:	train								test
exp2:	train							test	train
exp3:	train						test	train	
...	...								

- L'idée est de répéter l'expérience k fois : à chaque itération, vous testez sur 1/k des données et entraînez sur le reste.
- Ensuite, on fait la **moyenne des résultats** obtenus pour évaluer la performance globale.

Exemple : 10-fold cross validation

1. Collecter un grand ensemble d'exemples classifiés.
2. Diviser en deux ensembles disjoints : **entraînement (90%)** et **test (10%)**.
3. Appliquer l'algorithme sur l'ensemble d'entraînement.
4. Mesurer la performance avec l'ensemble de test.
5. Répéter avec les 10 portions différentes.
6. Faire la **moyenne des 10 expériences**.